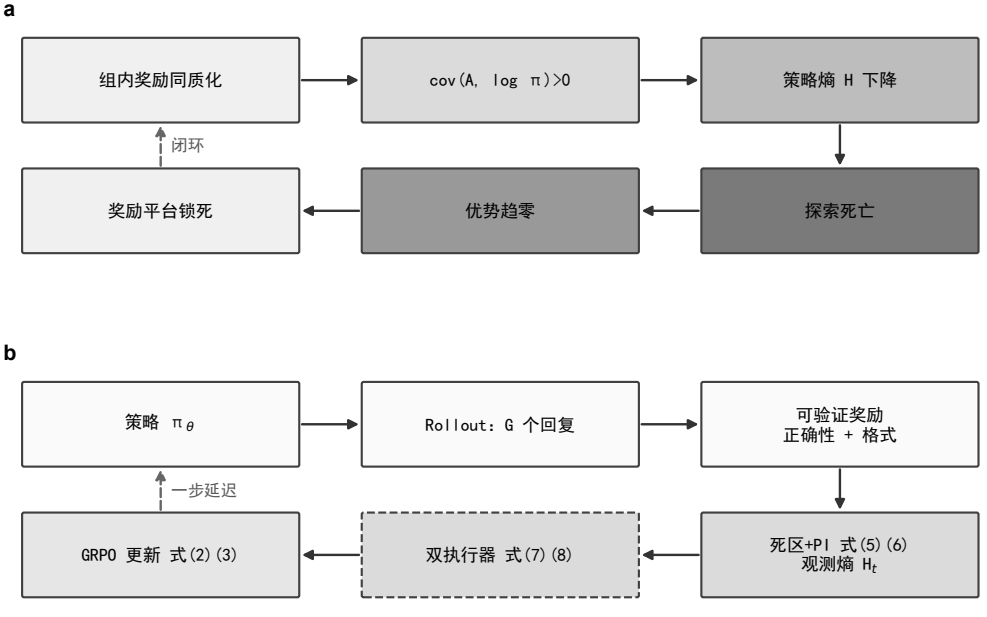
a
组内奖励同质化
cov(A, log π)>0
策略熵 H 下降
闭环
奖励平台锁死
优势趋零
探索死亡
b
策略 π_θ
Rollout：G 个回复
可验证奖励
正确性 + 格式
一步延迟
GRPO 更新 式(2)(3)
双执行器 式(7)(8)
死区+PI 式(5)(6)
观测熵 H_t