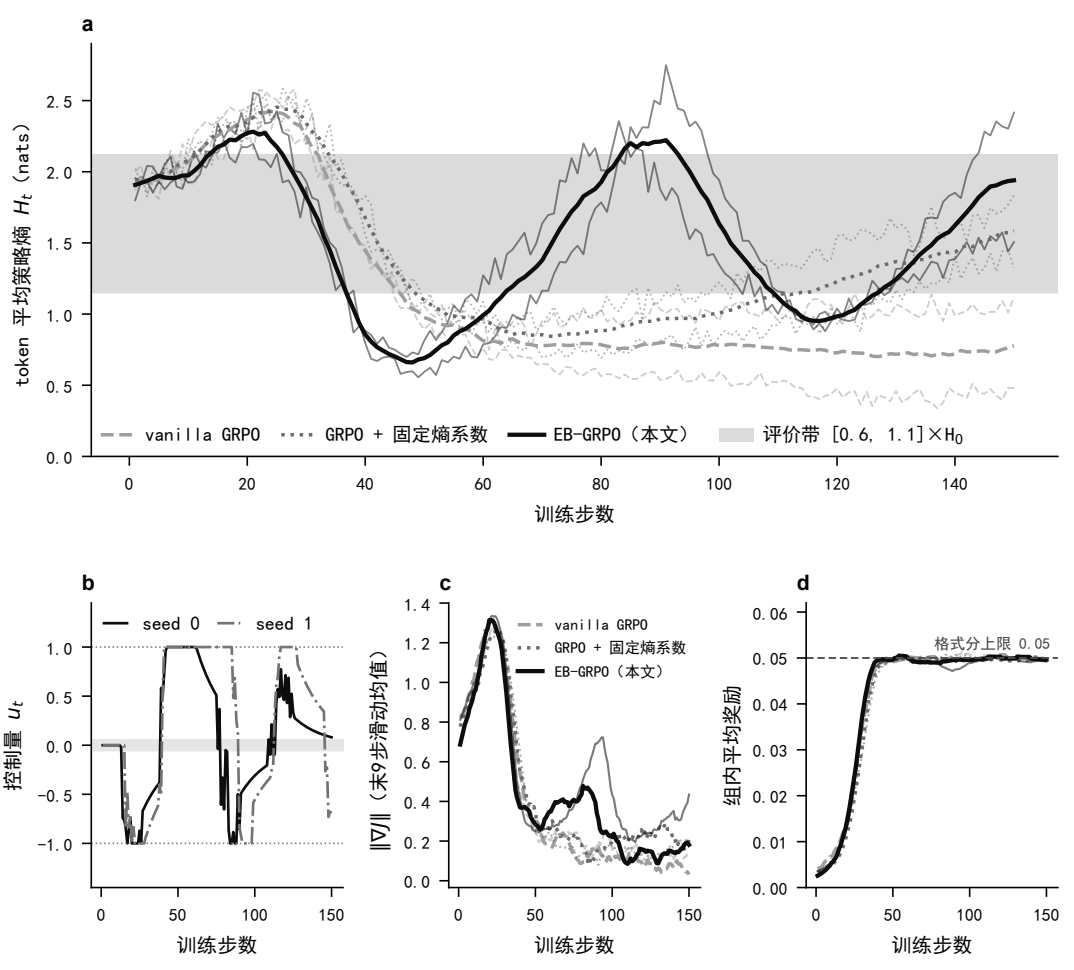

a
token 平均策略熵 H_t（nats）
2.5
2.0
1.5
1.0
0.5
0.0
0
20
40
60
80
100
120
140
训练步数
vanilla GRPO
GRPO + 固定熵系数
EB-GRPO（本文）
评价带 [0.6, 1.1]×H_0
b
控制量 u_t
seed 0
seed 1
1.0
0.5
0.0
−0.5
−1.0
0
50
100
150
训练步数
c
‖∇J‖（末9步滑动均值）
1.4
1.2
1.0
0.8
0.6
0.4
0.2
0.0
vanilla GRPO
GRPO + 固定熵系数
EB-GRPO（本文）
0
50
100
150
训练步数
d
组内平均奖励
0.06
0.05
0.04
0.03
0.02
0.01
0.00
格式分上限 0.05
0
50
100
150
训练步数